

1 統計量・標本分布と推定量

1.1 統計量と標本分布

定義 1.1: 無作為標本 (random sample)

標本 $X_1, \dots, X_n$ が互いに独立に同一の分布 F に従っているとき, $X_1, \dots, X_n$ を母集団分布 F から抽出された大きさ n の無作為標本という.

F の関数系が正規分布のように特定できる設定をパラメトリックといい, 関数系を特定しない設定をノンパラメトリックという. 標本 $X_1, \dots, X_n$ の関数 $T = T(X_1, \dots, X_n)$ で未知なものを含まないものを統計量 (statistic) といい, T の確率分布を標本分布 (sampling distribution) という. 以下の節で説明する標本平均, 標本分散, 順序統計量, 十分統計量は代表的な統計量である.

1.2 推定量と不偏性

パラメトリックなモデルの場合, $N(\mu, \sigma^2)$ の μ, σ^2 や $Ber(p)$ の p などの分布を特徴づける定数を母数 (parameter) といい, 未知の場合は標本から推定する. 一般に母数を θ で表すとき, θ を推定するには r.v. $X_1, \dots, X_n$ の関数で $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ と書ける. この $\hat{\theta}$ を推定量 (estimator) と呼ぶ. また, θ が取りうる値全体からなる集合を Θ で表し, パラメータ空間 (parameter space) という.

定義 1.2: 不偏性 (unbiasedness)

任意の $\theta \in \Theta$ に対して

$$E[\hat{\theta}] = \theta \quad (1.1)$$

が成り立つとき, 推定量 $\hat{\theta}$ は θ の不偏推定量 (unbiased estimator) であるという.

1.3 標本平均, 標本分散, 不偏分散

母集団の平均 μ や分散 σ^2 を母平均 (population mean), 母分散 (population variance) という. 母数は標本 $X_1, \dots, X_n$ から推定されて, 母平均 μ の推定量として標本平均 (sample mean)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1.2)$$

が定義され, 母分散 σ^2 の推定量として標本分散 (sample variance)

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.3)$$

が定義される.

平均 μ , 分散 σ^2 の確率分布を母集団とする無作為標本がとられているとする. これを

$$X_1, \dots, X_n, \quad \text{i.i.d.} \sim (\mu, \sigma^2) \quad (1.4)$$

と書く. このとき, 標本平均 $\bar{X}$ は μ の推定量であり, 不偏性を持つことが知られている.

例 1.1: 母数 θ が母平均 μ の場合 ($\theta = \mu$)

$\theta = \mu$ を推定するために、標本平均 $\bar{X}$ を推定量 $\hat{\theta}$ として用いる。すなわち、

$$\hat{\theta}(X_1, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1.5)$$

とする。 $E[X_i] = \mu, \text{Var}(X_i) = \sigma^2$ であるので、

$$E[\hat{\theta}] = E[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu \quad (1.6)$$

と推定量の期待値が母数 $\theta = \mu$ に一致する。定義 1.2 より、標本平均 $\bar{X}$ は母平均 μ の不偏推定量である。

標本平均 $\bar{X}$ の分散は

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{\sigma^2}{n} \quad (1.7)$$

となる。^[1]

例 1.2: 母数 θ が母分散 σ^2 の場合 ($\theta = \sigma^2$)

$\theta = \sigma^2$ を推定するために、標本分散 S^2 を推定量 $\hat{\theta}$ として用いる。すなわち、

$$\hat{\theta}(X_1, \dots, X_n) = S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.8)$$

とする。 $E[\hat{\theta}] = E[S^2] = \frac{1}{n} E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right]$ を計算する。ここで

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_i X_i^2 - 2\bar{X} \sum_i X_i + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 \quad (1.9)$$

であるので、

$$E\left[\sum_i (X_i - \bar{X})^2\right] = \sum_i E[X_i^2] - nE[\bar{X}^2] \quad (1.10)$$

となる。また、

$$\begin{aligned} \text{Var}(X_i) &= E[(X_i - \mu)^2] = E[X_i^2] - \mu^2 = \sigma^2 \\ \text{Var}(\bar{X}) &= E[(\bar{X} - \mu)^2] = E[\bar{X}^2] - \mu^2 = \frac{\sigma^2}{n} \end{aligned} \quad (1.11)$$

を用いると、(1.10) は

$$E\left[\sum_i (X_i - \bar{X})^2\right] = n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = (n-1)\sigma^2 \quad (1.12)$$

となる。したがって、

$$E[\hat{\theta}] = E[S^2] = \frac{1}{n} E\left[\sum_i (X_i - \bar{X})^2\right] = \frac{n-1}{n} \sigma^2 \quad (1.13)$$

と推定量 S^2 の期待値は母数 $\theta = \sigma^2$ に一致しない。定義 1.2 より、標本分散 S^2 は母分散 σ^2 の不偏推定量ではない。期待値が σ^2 になるには (1.12) から推定量 V^2 を

$$V^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.14)$$

と定義すればよい。このとき、定義 1.2 より、 V^2 は母分散 σ^2 の不偏推定量である。この V^2 を不偏分散 (unbiased variance) という。

[1] 二変数の場合では $\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$ が成り立ち、 $X \perp Y$ ならば $\text{Cov}(X, Y) = 0$ である。