

久保川 現代数理統計学の基礎 行間ノート

soph*

最終更新：2026 年 5 月 25 日

目次

1	統計量・標本分布と推定量	2
1.1	統計量と標本分布	2
1.2	推定量と不偏性	2
1.3	標本平均，標本分散，不偏分散	2
2	標本平均・標本分散の独立性と t 分布	4
2.1	標本平均と標本分散の独立性	4
2.2	t -分布	6
3	確率変数列の収束と漸近理論	7
3.1	確率収束と大数の弱法則	7
3.2	分布収束と中心極限定理	8
3.3	収束に関する諸結果	10
3.4	順序統計量	13

* <https://github.com/sophQFT>

1 統計量・標本分布と推定量

1.1 統計量と標本分布

定義 1.1: 無作為標本 (random sample)

標本 $X_1, \dots, X_n$ が互いに独立に同一の分布 F に従っているとき, $X_1, \dots, X_n$ を母集団分布 F から抽出された大きさ n の無作為標本という.

F の関数系が正規分布のように特定できる設定をパラメトリックといい, 関数系を特定しない設定をノンパラメトリックという. 標本 $X_1, \dots, X_n$ の関数 $T = T(X_1, \dots, X_n)$ で未知なものを含まないものを統計量 (statistic) といい, T の確率分布を標本分布 (sampling distribution) という. 以下の節で説明する標本平均, 標本分散, 順序統計量, 十分統計量は代表的な統計量である.

1.2 推定量と不偏性

パラメトリックなモデルの場合, $N(\mu, \sigma^2)$ の μ, σ^2 や $Ber(p)$ の p などの分布を特徴づける定数を母数 (parameter) といい, 未知の場合は標本から推定する. 一般に母数を θ で表すとき, θ を推定するには r.v. $X_1, \dots, X_n$ の関数で $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ と書ける. この $\hat{\theta}$ を推定量 (estimator) と呼ぶ. また, θ が取りうる値全体からなる集合を Θ で表し, パラメータ空間 (parameter space) という.

定義 1.2: 不偏性 (unbiasedness)

任意の $\theta \in \Theta$ に対して

$$E[\hat{\theta}] = \theta \quad (1.1)$$

が成り立つとき, 推定量 $\hat{\theta}$ は θ の不偏推定量 (unbiased estimator) であるという.

1.3 標本平均, 標本分散, 不偏分散

母集団の平均 μ や分散 σ^2 を母平均 (population mean), 母分散 (population variance) という. 母数は標本 $X_1, \dots, X_n$ から推定されて, 母平均 μ の推定量として標本平均 (sample mean)

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1.2)$$

が定義され, 母分散 σ^2 の推定量として標本分散 (sample variance)

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.3)$$

が定義される.

平均 μ , 分散 σ^2 の確率分布を母集団とする無作為標本がとられているとする. これを

$$X_1, \dots, X_n, \quad \text{i.i.d.} \sim (\mu, \sigma^2) \quad (1.4)$$

と書く. このとき, 標本平均 $\bar{X}$ は μ の推定量であり, 不偏性を持つことが知られている.

例 1.1: 母数 θ が母平均 μ の場合 ($\theta = \mu$)

$\theta = \mu$ を推定するために、標本平均 $\bar{X}$ を推定量 $\hat{\theta}$ として用いる。すなわち、

$$\hat{\theta}(X_1, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1.5)$$

とする。 $E[X_i] = \mu, \text{Var}(X_i) = \sigma^2$ であるので、

$$E[\hat{\theta}] = E[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu \quad (1.6)$$

と推定量の期待値が母数 $\theta = \mu$ に一致する。定義 1.2 より、標本平均 $\bar{X}$ は母平均 μ の不偏推定量である。

標本平均 $\bar{X}$ の分散は

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{\sigma^2}{n} \quad (1.7)$$

となる。^[1]

例 1.2: 母数 θ が母分散 σ^2 の場合 ($\theta = \sigma^2$)

$\theta = \sigma^2$ を推定するために、標本分散 S^2 を推定量 $\hat{\theta}$ として用いる。すなわち、

$$\hat{\theta}(X_1, \dots, X_n) = S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.8)$$

とする。 $E[\hat{\theta}] = E[S^2] = \frac{1}{n} E[\sum_{i=1}^n (X_i - \bar{X})^2]$ を計算する。ここで

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_i X_i^2 - 2\bar{X} \sum_i X_i + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 \quad (1.9)$$

であるので、

$$E[\sum_i (X_i - \bar{X})^2] = \sum_i E[X_i^2] - nE[\bar{X}^2] \quad (1.10)$$

となる。また、

$$\begin{aligned} \text{Var}(X_i) &= E[(X_i - \mu)^2] = E[X_i^2] - \mu^2 = \sigma^2 \\ \text{Var}(\bar{X}) &= E[(\bar{X} - \mu)^2] = E[\bar{X}^2] - \mu^2 = \frac{\sigma^2}{n} \end{aligned} \quad (1.11)$$

を用いると、(1.10) は

$$E[\sum_i (X_i - \bar{X})^2] = n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = (n-1)\sigma^2 \quad (1.12)$$

となる。したがって、

$$E[\hat{\theta}] = E[S^2] = \frac{1}{n} E[\sum_i (X_i - \bar{X})^2] = \frac{n-1}{n} \sigma^2 \quad (1.13)$$

と推定量 S^2 の期待値は母数 $\theta = \sigma^2$ に一致しない。定義 1.2 より、標本分散 S^2 は母分散 σ^2 の不偏推定量ではない。期待値が σ^2 になるには (1.12) から推定量 V^2 を

$$V^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.14)$$

と定義すればよい。このとき、定義 1.2 より、 V^2 は母分散 σ^2 の不偏推定量である。この V^2 を不偏分散 (unbiased variance) という。

[1] 二変数の場合では $\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$ が成り立ち、 $X \perp Y$ ならば $\text{Cov}(X, Y) = 0$ である。

2 標本平均・標本分散の独立性と t 分布

2.1 標本平均と標本分散の独立性

平均 μ , 分散 σ^2 の正規分布に従う母集団（正規母集団）から、無作為標本がとられているとする。無作為抽出とは r.v. $X_1, \dots, X_n$ が独立であると言い換えることができる。すなわち、

$$X_1, \dots, X_n, \quad \text{i.i.d.} \sim N(\mu, \sigma^2) \quad (2.1)$$

ここで、

$$\text{標本平均: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \text{不偏分散: } V^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (2.2)$$

について次の定理が成り立つ。

定理 2.1: 正規母集団からの無作為標本

$X_1, \dots, X_n$ を正規母集団 $N(\mu, \sigma^2)$ からの無作為標本とする。このとき、次が成り立つ。

- (1) 標本平均 $\bar{X}$ と標本不偏分散 V^2 は独立に分布する。
- (2) $\bar{X} \sim N(\mu, \sigma^2/n)$
- (3) $\frac{(n-1)V^2}{\sigma^2} \sim \chi_{n-1}^2$

Proof (2.1) から、

$$Z_i = \frac{X_i - \mu}{\sigma} \quad (2.3)$$

と変換した r.v. $Z_1, \dots, Z_n$ は i.i.d. $N(0, 1)$ に従う。ここで、標準化した標本平均を、 $\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i$ とおくと、

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i = \frac{1}{n\sigma} \sum_{i=1}^n (X_i - \mu) = \frac{1}{\sigma} (\bar{X} - \mu) \quad (2.4)$$

となる。(3.18) を変形すると、

$$\sqrt{n}\bar{Z} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \quad (2.5)$$

となる。これは、(2) の主張が成り立つなら、 $\bar{X} \sim N(\mu, \sigma^2/n)$ を標準化して、 $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ となることと同値である。つまり、(2) は、 $\sqrt{n}\bar{Z} \sim N(0, 1)$ と書き直せる。

また、(2.3), (3.18) より、

$$X_i - \bar{X} = (\sigma Z_i + \mu) - (\sigma \bar{Z} + \mu) = \sigma(Z_i - \bar{Z}) \quad (2.6)$$

であるから、不偏分散 V^2 は

$$V^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{\sigma^2}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2 \quad (2.7)$$

と書ける。これを (3) の主張に代入すると、

$$\frac{(n-1)V^2}{\sigma^2} = \sum_{i=1}^n (Z_i - \bar{Z})^2 \quad (2.8)$$

となる。すなわち (3) の主張は、 $\sum_{i=1}^n (Z_i - \bar{Z})^2 \sim \chi_{n-1}^2$ であることと同値である。

さらに, (3.18), (2.7) より,

$$\bar{X} = \sigma \bar{Z} + \mu, \quad V^2 = \frac{\sigma^2}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2$$

だったので, (1) の主張は, $\bar{Z}$ と $\sum_{i=1}^n (Z_i - \bar{Z})^2$ の独立性と同値である. 以上から, 定理の (1),(2),(3) は, それぞれ

- (1') $\bar{Z}$ と $\sum_{i=1}^n (Z_i - \bar{Z})^2$ は独立に分布する.
 (2') $\sqrt{n}\bar{Z} \sim N(0, 1)$
 (3') $\sum_{i=1}^n (Z_i - \bar{Z})^2 \sim \chi_{n-1}^2$

と書き直す事ができる. そこで, $Z_1, \dots, Z_n$ が i.i.d. $N(0, 1)$ に従うことから, (1'),(2'),(3') を示す.

まず, $Z = (Z_1, \dots, Z_n)^T$ から $Y = (Y_1, \dots, Y_n)^T$ への変換 $Y = HZ$ を考える. ここで, $H \in \text{GL}(n, \mathbb{R})$ は以下のような直交行列である.

$$H = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & \cdots & 0 \\ \frac{1}{\sqrt{2 \cdot 3}} & \frac{1}{\sqrt{2 \cdot 3}} & -\frac{2}{\sqrt{2 \cdot 3}} & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \ddots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \cdots & -\frac{n-1}{\sqrt{n(n-1)}} \end{pmatrix} \quad (2.9)$$

直交行列 H は, 1 行目が $(1/\sqrt{n}, \dots, 1/\sqrt{n})$ であり, 2 行目以降は互いに直交するように構成されて, 第 k 行 ($k = 2, \dots, n$) は

$$\frac{1}{\sqrt{k(k-1)}} (\underbrace{1, \dots, 1}_{k-1 \text{ 個}}, -(k-1), 0, \dots, 0)$$

で構成される. この行列 H をヘルマート (Helmert) 行列と呼ぶ.

さて, 直交変換前の r.v. $Z_1, \dots, Z_n, \text{i.i.d.} \sim N(0, 1)$ であることから, $Z = (Z_1, \dots, Z_n)^T$ における joint p.d.f. は

$$f_Z(z) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z_i^2}{2}\right) = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} z^T z\right) \quad (2.10)$$

である. ここで, $Y = HZ$ の変換に対して, Y の joint p.d.f. は

$$f_Y(y) = f_Z(z(y)) \left| \frac{\partial(z_1, \dots, z_n)}{\partial(y_1, \dots, y_n)} \right| \quad (2.11)$$

であった. ここで, ヤコビアンは

$$\left| \frac{\partial(z_1, \dots, z_n)}{\partial(y_1, \dots, y_n)} \right| = \left| \frac{1}{\frac{\partial(y_1, \dots, y_n)}{\partial(z_1, \dots, z_n)}} \right| = \frac{1}{|\det(H)|} = 1 \quad (2.12)$$

となる. [2] また, $z = H^{-1}y = H^T y$ であることから, $z^T z = y^T (HH^T) y = y^T y$ である. したがって, Y の joint p.d.f. は (2.11), (2.12) より,

$$f_Y(y) = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} y^T y\right) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y_i^2}{2}\right) \quad (2.13)$$

となる. つまり,

$$Y_1, \dots, Y_n \text{ i.i.d.} \sim N(0, 1) \quad (2.14)$$

[2] $Y_i = \sum_{j=1}^n H_{ij} Z_j$ より, $\frac{\partial y_i}{\partial z_j} = H_{ij}$ である.

である。ヘルマート行列の1行目の成分は $(1/\sqrt{n}, \dots, 1/\sqrt{n})$ であり、 $Y = HZ$ の1成分目は

$$Y_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i = \sqrt{n} \bar{Z} \quad (2.15)$$

である。したがって、 $Y_1 = \sqrt{n} \bar{Z} \sim N(0, 1)$ であり、(2') が成り立つ。 $\sum_{i=1}^n (Z_i - \bar{Z})^2$ は、 $Y_2, \dots, Y_n$ を用いて

$$\begin{aligned} \sum_{i=1}^n (Z_i - \bar{Z})^2 &= \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = \sum_{i=1}^n Z_i^2 - n\bar{Z}^2 \\ &= \sum_{i=1}^n Z_i^2 - Y_1^2 = Y^T Y - Y_1^2 = \sum_{i=2}^n Y_i^2 \end{aligned} \quad (2.16)$$

と書ける。ここで、 $Z^T Z = Y^T Y$ を用いた。独立な標準正規分布に従う r.v. の二乗和はカイ二乗分布に従い、その自由度は和の項数に等しいので、(2.14)、(2.16) より、

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 \sim \chi_{n-1}^2 \quad (2.17)$$

となり、(3') が成り立つ。

最後に、 $Y_1, \dots, Y_n$ の独立性から、 Y_1 と $(Y_2, \dots, Y_n)^T$ は独立である。 $\bar{Z}$ は Y_1 のみの関数であり、 $\sum_{i=1}^n (Z_i - \bar{Z})^2$ は $(Y_2, \dots, Y_n)^T$ のみの関数であるから、 $\bar{Z} \perp \sum_{i=1}^n (Z_i - \bar{Z})^2$ であり、(1') が成り立つ。 ■

2.2 t-分布

$X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ とする。このとき、定理 2.1、(2.5) から新たな r.v. Z を

$$Z := \sqrt{n} \bar{Z} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \quad (2.18)$$

と定義すると、 $Z \sim N(0, 1)$ である。ここで母分散 σ^2 の代わりに不偏分散 V^2 を用いて、r.v. T を

$$T := \frac{\bar{X} - \mu}{V/\sqrt{n}} \quad (2.19)$$

と定義し、この確率分布を考える。 μ に既知の値が入るとき、この r.v. を **t-統計量** という。r.v. U を

$$U := \frac{(n-1)V^2}{\sigma^2} \quad (2.20)$$

と定義すると、定理 2.1 から $U \sim \chi_{n-1}^2$ であり、 $\bar{X} \perp V^2$ から $Z \perp U$ である。(2.19)、(2.20) より、

$$T = \frac{\bar{X} - \mu}{V/\sqrt{n}} = \frac{Z}{\sqrt{\frac{U}{n-1}}} \quad (2.21)$$

と書き直すことができる。この **t-統計量** は、r.v. $Z \sim N(0, 1)$ と $U \sim \chi_{n-1}^2$ を組み合わせて作られた分布である。 T の従う分布は自由度 $n-1$ の t-分布と呼ばれる。 $m = n-1$ として、自由度 m の t-分布の定義を与える。

定義 2.1: 自由度 m の t-分布

r.v. $Z \sim N(0, 1)$ と $U \sim \chi_m^2$ が独立であるとき、

$$T = \frac{Z}{\sqrt{U/m}} \quad (2.22)$$

と定義される r.v. T の分布を、自由度 m のスチューデントの t-分布といい、この分布を t_m で表す。

3 確率変数列の収束と漸近理論

3.1 確率収束と大数の弱法則

確率変数の列 $U_1, U_2, \dots$ を $\{U_n\}_{n=1,2,\dots}$ と表記することにする.

定義 3.1: 確率収束 (convergence in probability)

確率変数の列 $\{U_n\}$ が確率変数 U に確率収束するとは, 任意の $\epsilon > 0$ に対して

$$\lim_{n \rightarrow \infty} \mathbb{P}(|U_n - U| \geq \epsilon) = 0 \quad (3.1)$$

が成り立つことをいう. このとき, $U_n \xrightarrow{p} U$ と表記する.

確率収束を示すのに, 次の不等式を用いると便利である.

補題 3.1: マルコフの不等式 (Markov's inequality)

$Y \geq 0$ なる r.v. Y に対し, $E[Y] < \infty$ とする. このとき任意の $c > 0$ に対して次の不等式が成り立つ.

$$\mathbb{P}(Y \geq c) \leq \frac{E[Y]}{c} \quad (3.2)$$

Proof 指示関数^[3] $I_{[Y \geq c]}$, $I_{[Y < c]}$ をそれぞれ

$$I_{[Y \geq c]} = \begin{cases} 1 & (Y \geq c) \\ 0 & (Y < c) \end{cases}, \quad I_{[Y < c]} = \begin{cases} 1 & (Y < c) \\ 0 & (Y \geq c) \end{cases} \quad (3.3)$$

と定める. r.v. Y は非負であるから,

$$Y = Y\{I_{[Y \geq c]} + I_{[Y < c]}\} \geq Y I_{[Y \geq c]} \geq c I_{[Y \geq c]} \quad (3.4)$$

となる. 両辺の期待値を取ると,

$$E[Y] \geq c E[I_{[Y \geq c]}] \quad (3.5)$$

となる. ここで,

$$E[I_{[Y \geq c]}] = 1 \cdot \mathbb{P}(Y \geq c) + 0 \cdot \mathbb{P}(Y < c) = \mathbb{P}(Y \geq c) \quad (3.6)$$

であるから, (3.5) に適用するとマルコフの不等式が得られる. ■

補題 3.2: チェビシェフの不等式 (Chebyshev's inequality)

r.v. X について平均と分散, $\mu = E[X]$, $\sigma^2 = \text{Var}(X)$ が存在すると仮定する. このとき次の不等式が成り立つ.

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2} \quad (3.7)$$

Proof マルコフの不等式に於いて, $Y = (X - \mu)^2$, $c = k^2$ とおく. (3.2) より,

$$\mathbb{P}((X - \mu)^2 \geq k^2) \leq \frac{E[(X - \mu)^2]}{k^2} \quad (3.8)$$

[3] 集合 A 上で 1, A の外で 0 である関数,

$$I_A = \begin{cases} 1 & (x \in A) \\ 0 & (x \notin A) \end{cases}$$

を A の指示関数 (indicator function) という.

となる．ここで， $\mathbb{P}((X - \mu)^2 \geq k^2) = \mathbb{P}(|X - \mu| \geq k)$ ， $E[(X - \mu)^2] = \text{Var}(X) = \sigma^2$ であるから，(3.7) が得られる． ■

チェビシェフの不等式を用いると，標本平均の確率収束が示される．これを大数の弱法則 (weak law of large numbers) という．

定理 3.3: 大数の弱法則 (weak law of large numbers)

r.v. $X_1, \dots, X_n$ を平均 μ ，分散 σ^2 とする同一の確率分布からの無作為標本とする．すなわち $X_1, \dots, X_n$ i.i.d. $\sim (\mu, \sigma^2)$ とし， $\sigma^2 = \text{Var}(X_i) < \infty$ とする．このとき，標本平均 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ は母平均 μ に確率収束する．すなわち，任意の $\epsilon > 0$ に対して

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0 \quad (3.9)$$

が成り立つ．

Proof チェビシェフの不等式より，

$$0 \leq \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2} \quad (3.10)$$

となる． $n \rightarrow \infty$ とすると $\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \rightarrow 0$ となり，確率収束することが分かる． ■

標本平均 $\bar{X}$ が母平均 μ に確率収束するので，これを $\bar{X} \xrightarrow{p} \mu$ と表記する．

3.2 分布収束と中心極限定理

定義 3.2: 分布収束 (convergence in distribution)

r.v. の列 $\{U_n\}_{n=1,2,\dots}$ が r.v. U に分布収束するとは， U_n の分布関数 $F_{U_n}(x)$ が r.v. U の分布関数 $F_U(x)$ に各点 x で収束することをいう．すなわち，任意の $x \in \mathbb{R}$ に対して

$$\lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq x) = \lim_{n \rightarrow \infty} F_{U_n}(x) = F_U(x) \quad (3.11)$$

が成り立つことをいう．このとき， $U_n \xrightarrow{d} U$ と表記する．

注意

$U_n \xrightarrow{d} F_U$ のように記すこともある．また $X \sim N(0, \sigma^2)$ のとき， $X_n \xrightarrow{d} N(0, \sigma^2)$ と書くこともある．

定理 3.4: 特性関数の連続性定理

r.v. の列 $\{U_n\}_{n=1,2,\dots}$ が r.v. U に分布収束することと，任意の $t \in \mathbb{R}$ に対して r.v. U_n の特性関数 $\varphi_{U_n}(t)$ が r.v. U の特性関数 $\varphi_U(t)$ に収束することは同値である．すなわち，

$$\lim_{n \rightarrow \infty} F_{U_n}(x) = F_U(x) \quad \Leftrightarrow \quad \lim_{n \rightarrow \infty} \varphi_{U_n}(t) = \varphi_U(t), \quad \forall t \in \mathbb{R} \quad (3.12)$$

が成り立つ．

Proof X が連続型 r.v. のとき，特性関数 $\varphi_X(t)$ は

$$\varphi_X(t) = E[e^{itX}] = \int_{-\infty}^{\infty} e^{itx} f_X(x) dx \quad (3.13)$$

と表される．ここで， $f_X(x)$ は r.v. X の p.d.f. である．(3.13) は $f_X(x)$ を Fourier 変換したものに過ぎないので，

逆変換を施すと,

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \varphi_X(t) dt \quad (3.14)$$

となる. このように確率分布と特性関数は一対一に対応している. 収束に関しても特性関数の各点収束と分布収束が一対一に対応している. ■

定理 3.5: 中心極限定理 (central limit theorem)

r.v. $X_1, X_2, \dots$ を平均 μ , 分散 σ^2 を持つ同一の確率分布からの無作為標本とする. すなわち, $X_1, X_2, \dots$ i.i.d. $\sim (\mu, \sigma^2)$ とし, 次の分布収束が成り立つ. ここで, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ は標本平均である.

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1) \quad (3.15)$$

(3.15) は,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \leq x \right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-y^2/2} dy = \Phi(x) \quad (3.16)$$

と書き直せる. ここで, $\Phi(x)$ は標準正規分布 $N(0, 1)$ の分布関数である.

Proof $E[\bar{X}] = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$ であるから, $\bar{X}$ を標準化すると,

$$U_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \quad (3.17)$$

となる. $E[X_i] = \mu$, $\text{Var}(X_i) = \sigma^2$ であるから, X_i を標準化すると, $Z_i = \frac{X_i - \mu}{\sigma}$ となる. $\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i$ とおくと,

$$\bar{Z} = \frac{1}{n} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{\bar{X} - \mu}{\sigma} \quad (3.18)$$

であり, (3.18) から

$$\sqrt{n}\bar{Z} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \quad (3.19)$$

と書ける. (3.17) と見比べると, $U_n = \sqrt{n}\bar{Z}$ が $\bar{X}$ を標準化した r.v. である. したがって, $U_n = \sqrt{n}\bar{Z}$ が $N(0, 1)$ に分布収束することを示せばよい. このことは定理 3.4 より, U_n の特性関数の $n \rightarrow \infty$ での極限 $\lim \varphi_{U_n}(t)$ が $N(0, 1)$ の特性関数 $\varphi_{N(0,1)}(t) = e^{-t^2/2}$ に一致することを示すことと同等である.

さて, $U_n = \sqrt{n}\bar{Z} = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i$ の特性関数は, Z_i が互いに独立であることに注意して

$$\varphi_{\sqrt{n}\bar{Z}}(t) = E[e^{it\sqrt{n}\bar{Z}}] = E[e^{it\frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i}] = E[e^{i\frac{t}{\sqrt{n}} Z_1} \cdot e^{i\frac{t}{\sqrt{n}} Z_2} \cdots e^{i\frac{t}{\sqrt{n}} Z_n}] = \prod_{i=1}^n E[e^{i\frac{t}{\sqrt{n}} Z_i}] \quad (3.20)$$

と計算できる. $Z_1, \dots, Z_n$ i.i.d. $\sim N(0, 1)$ であるから, 各 r.v. に対応する特性関数も一致するので,

$$\varphi_{Z_1} \left(\frac{t}{\sqrt{n}} \right) = \cdots = \varphi_{Z_n} \left(\frac{t}{\sqrt{n}} \right) = E[e^{i\frac{t}{\sqrt{n}} Z_1}] \quad (3.21)$$

となり, $U_n = \sqrt{n}\bar{Z}$ の特性関数は (3.20) から,

$$\varphi_{\sqrt{n}\bar{Z}}(t) = \left\{ \varphi_{Z_1} \left(\frac{t}{\sqrt{n}} \right) \right\}^n \quad (3.22)$$

と書ける. (3.22) の $n \rightarrow \infty$ での極限を取り, $N(0, 1)$ の特性関数に一致することを示す. $n \gg 1$ のとき, 特性関数 $\varphi_{Z_1} \left(\frac{t}{\sqrt{n}} \right)$ をテイラー展開すると,

$$\varphi_{Z_1} \left(\frac{t}{\sqrt{n}} \right) = \varphi_{Z_1}(0) + \varphi'_{Z_1}(0) \frac{t}{\sqrt{n}} + \frac{1}{2} \varphi''_{Z_1}(0) \left(\frac{t}{\sqrt{n}} \right)^2 + \frac{1}{3!} \varphi^{(3)}_{Z_1}(0) \left(\frac{t}{\sqrt{n}} \right)^3 + \cdots$$

$$= 1 - \frac{t^2}{2n} + \mathcal{O}(n^{-3/2}) \quad (3.23)$$

となるので, (3.22) は

$$\varphi_{\sqrt{n}\bar{Z}}(t) = \left(1 - \frac{t^2}{2n} + \mathcal{O}(n^{-3/2})\right)^n \quad (3.24)$$

となり, $n \rightarrow \infty$ の極限を取ると,

$$\lim_{n \rightarrow \infty} \varphi_{\sqrt{n}\bar{Z}}(t) = \lim_{n \rightarrow \infty} \left(1 - \frac{t^2}{2n} + \mathcal{O}(n^{-3/2})\right)^n = e^{-t^2/2} \quad (3.25)$$

となる. これは $N(0, 1)$ の特性関数に一致するので, 定理 3.4 より, $U_n = \sqrt{n}\bar{Z}$ は $N(0, 1)$ に分布収束する. ■

3.3 収束に関する諸結果

分布収束と確率収束との関係が次の命題で与えられる.

命題 3.6:

r.v. の列 $\{U_n\}_{n=1,2,\dots}$ と r.v. U を考える.

- (1) $U_n \xrightarrow{p} U$ ならば, $U_n \xrightarrow{d} U$
- (2) a を定数とすると, $U_n \xrightarrow{d} a$ ならば, $U_n \xrightarrow{p} a$

Proof 最初に,

r.v.'s S, T と実数 w と $\epsilon > 0$ に対して不等式

$$\mathbb{P}(S \leq w - \epsilon) - \mathbb{P}(|S - T| > \epsilon) \leq \mathbb{P}(T \leq w) \leq \mathbb{P}(S \leq w + \epsilon) + \mathbb{P}(|S - T| > \epsilon) \quad (3.26)$$

が成り立つことを示す. $\mathbb{P}(T \leq w)$ を

$$\mathbb{P}(T \leq w) = \mathbb{P}(T \leq w, |S - T| \leq \epsilon) + \mathbb{P}(T \leq w, |S - T| > \epsilon) \quad (3.27)$$

と分解する. ここで (3.27) の第 2 項に対して,

$$\mathbb{P}(T \leq w, |S - T| > \epsilon) \leq \mathbb{P}(|S - T| > \epsilon) \quad (3.28)$$

が成り立つ. また, (3.27) の第 1 項に対しては, $|S - T| \leq \epsilon$ ならば $T - \epsilon \leq S \leq T + \epsilon$ であり, $T \leq w$ であるから $S \leq w + \epsilon$ が成り立つので, $\{T \leq w, |S - T| \leq \epsilon\} \subseteq \{S \leq w + \epsilon\}$ となり,

$$\mathbb{P}(T \leq w, |S - T| \leq \epsilon) \leq \mathbb{P}(S \leq w + \epsilon) \quad (3.29)$$

が成り立つ. (3.28), (3.29) から (3.27) の右辺を評価すると,

$$\mathbb{P}(T \leq w) \leq \mathbb{P}(S \leq w + \epsilon) + \mathbb{P}(|S - T| > \epsilon) \quad (3.30)$$

が得られる. この不等式に於いて w を $w - \epsilon$ に置き換え, S と T を交換すると,

$$\mathbb{P}(S \leq w - \epsilon) - \mathbb{P}(|S - T| > \epsilon) \leq \mathbb{P}(T \leq w) \quad (3.31)$$

が得られる. (3.30) と (3.31) を合わせると, (3.26) が得られる.

(1) に関しては $U_n \xrightarrow{p} U \Rightarrow U_n \xrightarrow{d} U$, すなわち $\lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq x) = \mathbb{P}(U \leq x)$ を示せばよい. (3.26) に於いて, $S = U, T = U_n, w = x$ とおくと,

$$\mathbb{P}(U \leq x - \epsilon) - \mathbb{P}(|U - U_n| > \epsilon) \leq \mathbb{P}(U_n \leq x) \leq \mathbb{P}(U \leq x + \epsilon) + \mathbb{P}(|U - U_n| > \epsilon) \quad (3.32)$$

と書ける. $U_n \xrightarrow{p} U$, すなわち $\lim_{n \rightarrow \infty} \mathbb{P}(|U - U_n| > \epsilon) = 0$ であるから, (3.32) の $n \rightarrow \infty$ での極限を取ると,

$$\mathbb{P}(U \leq x - \epsilon) \leq \lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq x) \leq \mathbb{P}(U \leq x + \epsilon) \quad (3.33)$$

となる. $F_U(x)$ が x で連続であることから, $\epsilon \rightarrow 0$ とすると, $\lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq x) = \mathbb{P}(U \leq x)$ となり $U_n \xrightarrow{d} U$ が示される.

(2) に関しては $U_n \xrightarrow{d} a \Rightarrow U_n \xrightarrow{p} a$, すなわち $\lim_{n \rightarrow \infty} \mathbb{P}(|U_n - a| > \epsilon) = 0$ を示せばよい.

$$\begin{aligned} \mathbb{P}(|U_n - a| > \epsilon) &= \mathbb{P}(U_n > a + \epsilon) + \mathbb{P}(U_n < a - \epsilon) \\ &\leq 1 - \mathbb{P}(U_n \leq a + \epsilon) + \mathbb{P}(U_n \leq a - \epsilon) \end{aligned} \quad (3.34)$$

である. $U_n \xrightarrow{d} a$ は, $\lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq x) = \lim_{n \rightarrow \infty} F_{U_n}(x) = \mathbb{P}(a \leq x) = F_a(x)$ であるので,

$$F_a(x) = \begin{cases} 0 & (x < a) \\ 1 & (x \geq a) \end{cases} \quad (3.35)$$

である. $x = a + \epsilon$ と $x = a - \epsilon$ を (3.35) に適用すると

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq a - \epsilon) &= F_a(a - \epsilon) = 0 \\ \lim_{n \rightarrow \infty} \mathbb{P}(U_n \leq a + \epsilon) &= F_a(a + \epsilon) = 1 \end{aligned} \quad (3.36)$$

となる. (3.34) の $n \rightarrow \infty$ での極限を取ると, (3.36) より,

$$0 \leq \lim_{n \rightarrow \infty} \mathbb{P}(|U_n - a| > \epsilon) \leq 1 - 1 + 0 = 0 \quad (3.37)$$

となり, $U_n \xrightarrow{p} a$ が示される. ■

分布収束の同値な条件として次の定理が知られている.

定理 3.7: ポートマントーの補題 (Portmanteau's lemma)

r.v. の列 $\{U_n\}_{n=1,2,\dots}$ と r.v. U を考える. このとき, $U_n \xrightarrow{d} U$ となる必要十分条件は, 任意の有界連続な関数 $f: \mathbb{R} \rightarrow \mathbb{R}$ に対して

$$\lim_{n \rightarrow \infty} E[f(U_n)] = E[f(U)] \quad (3.38)$$

が成り立つことである.

Proof <https://ibis.t.u-tokyo.ac.jp/suzuki/lecture/2021/elemprob/確率数理要論4.pdf> や https://mcm-www.jwu.ac.jp/~konno/pdf/stat_rikkyo-2024_ch4_0914.pdf を参照. ■

命題 3.8: 連続写像定理 (continuous mapping theorem)

r.v. の列 $\{U_n\}_{n=1,2,\dots}$ と r.v. U を考える. $h: \mathbb{R} \rightarrow \mathbb{R}$ を連続関数とする. このとき, 次が成り立つ.

- (1) $U_n \xrightarrow{p} U$ ならば, $h(U_n) \xrightarrow{p} h(U)$
- (2) $U_n \xrightarrow{d} U$ ならば, $h(U_n) \xrightarrow{d} h(U)$

Proof (2) のみ示す. $h(U_n) \xrightarrow{d} h(U)$ は定理 3.7 より, 任意の有界連続な関数 $f: \mathbb{R} \rightarrow \mathbb{R}$ に対して

$$\lim_{n \rightarrow \infty} E[f(h(U_n))] = E[f(h(U))] \quad (3.39)$$

と書けるので, (3.39) を示せばよい. $g = f \circ h$ とおくと, g も有界連続な関数であるから, $U_n \xrightarrow{d} U$ より,

$$\lim_{n \rightarrow \infty} E[g(U_n)] = E[g(U)] \quad (3.40)$$

が成り立つ. (3.40) に $g = f \circ h$ を代入すると, (3.39) が得られる. ■

命題 3.9: スラツキーの定理 (Slutzky's theorem)

r.v. の列 $\{U_n\}_{n=1,2,\dots}$ と $\{V_n\}_{n=1,2,\dots}$, r.v. U , 定数 a に対して, $U_n \xrightarrow{d} U$, $V_n \xrightarrow{p} a$ が成り立つとする. このとき, 次が成り立つ.

- (1) $U_n + V_n \xrightarrow{d} U + a$
- (2) $U_n V_n \xrightarrow{d} aU$

Proof 命題 3.6 より, $V_n \xrightarrow{p} a \Rightarrow V_n \xrightarrow{d} a$ である. このことから, $(U_n, V_n) \xrightarrow{d} (U, a)$ が成り立つ. ここで, 有界連続な関数 $h_1, h_2: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ を

$$h_1(U_n, V_n) = U_n + V_n, \quad h_2(U_n, V_n) = U_n V_n \quad (3.41)$$

と定義する. 連続写像定理より,

$$h_1(U_n, V_n) = U_n + V_n \xrightarrow{d} h_1(U, a) = U + a \quad (3.42)$$

および

$$h_2(U_n, V_n) = U_n V_n \xrightarrow{d} h_2(U, a) = aU \quad (3.43)$$

が成り立つ. ■

スラツキーの定理の証明は, 同時分布の収束や 2 変数関数に対する連続写像定理を使わないでも, 直接示すことができる.

Proof (1) については, x を U の分布関数の連続点とし, 不等式 (3.26) に於いて, $S = U_n + a, T = U_n + V_n, w = x$ とおくと,

$$\mathbb{P}(U_n \leq x - a - \epsilon) - \mathbb{P}(|V_n - a| > \epsilon) \leq \mathbb{P}(U_n + V_n \leq x) \leq \mathbb{P}(U_n \leq x - a + \epsilon) + \mathbb{P}(|V_n - a| > \epsilon) \quad (3.44)$$

となる. (3.44) の $n \rightarrow \infty$ での極限を取ると, $U_n \xrightarrow{d} U$, $V_n \xrightarrow{p} a$ であるから,

$$\mathbb{P}(U \leq x - a - \epsilon) \leq \lim_{n \rightarrow \infty} \mathbb{P}(U_n + V_n \leq x) \leq \mathbb{P}(U \leq x - a + \epsilon) \quad (3.45)$$

となる. $\epsilon \rightarrow 0$ とすると, U の分布関数が $x - a$ で連続であることから,

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{P}(U_n + V_n \leq x) &= \mathbb{P}(U \leq x - a) \\ &= \mathbb{P}(U + a \leq x) \end{aligned} \quad (3.46)$$

より, $U_n + V_n \xrightarrow{d} U + a$ が示される.

(2) については, $U_n V_n = U_n V_n - aU_n + aU_n = U_n(V_n - a) + aU_n$ とし,

$$U_n(V_n - a) + aU_n \xrightarrow{d} aU \quad (3.47)$$

を示す. $aU_n \xrightarrow{d} aU$ に注意^[4] すると, スラツキーの定理 (1) より (3.47) を示すためには $U_n \xrightarrow{d} U, V_n \xrightarrow{p} a$ のとき,

$$U_n(V_n - a) \xrightarrow{p} 0 \quad (3.48)$$

を示せばよい. ここで $V_n \xrightarrow{p} a$ で, 有界連続な関数 $h: \mathbb{R} \rightarrow \mathbb{R}$ を $h(V_n) = V_n - a$ と定義すると, 連続写像定理より

$$h(V_n) = V_n - a \xrightarrow{p} h(a) = 0 \quad (3.49)$$

[4] $h(U_n) = aU_n$ と定義すると, $h(U_n) \xrightarrow{d} h(U)$ となるので, $aU_n \xrightarrow{d} aU$ が成り立つ.

となるので $V'_n = V_n - a$ とおくと (3.48) は $U_n \xrightarrow{d} U, V'_n \xrightarrow{p} 0$ のとき,

$$U_n V'_n \xrightarrow{p} 0 \quad (3.50)$$

を示すことに帰着する. すなわち (3.48) で $a = 0$ の場合, $U_n \xrightarrow{d} U, V_n \xrightarrow{p} 0$ のとき, $U_n V_n \xrightarrow{p} 0$ を示せばよい.
 $\epsilon > 0, \delta > 0$ に対して,

$$\mathbb{P}(|U_n V_n| > \epsilon) = \mathbb{P}(|U_n V_n| > \epsilon, |V_n| \leq \delta) + \mathbb{P}(|U_n V_n| > \epsilon, |V_n| > \delta) \quad (3.51)$$

と分解する. (3.51) の第 2 項に対して,

$$\mathbb{P}(|U_n V_n| > \epsilon, |V_n| > \delta) \leq \mathbb{P}(|V_n| > \delta) \quad (3.52)$$

が成り立つ. また, (3.51) の第 1 項に対しては, $|V_n| \leq \delta \Leftrightarrow 1/|V_n| \geq 1/\delta$ であるから,

$$|U_n| = \frac{|U_n V_n|}{|V_n|} \geq \frac{|U_n V_n|}{\delta} \quad (3.53)$$

となり, $|U_n V_n| > \epsilon$ も考慮すると, $|U_n| > \epsilon/\delta$ となる. すなわち $\{|U_n V_n| > \epsilon, |V_n| \leq \delta\} \subseteq \{|U_n| > \epsilon/\delta\}$ となるので,

$$\mathbb{P}(|U_n V_n| > \epsilon, |V_n| \leq \delta) \leq \mathbb{P}(|U_n| > \epsilon/\delta) \quad (3.54)$$

が成り立つ. (3.52) と (3.54) を (3.51) に適用すると,

$$\mathbb{P}(|U_n V_n| > \epsilon) \leq \mathbb{P}(|U_n| > \epsilon/\delta) + \mathbb{P}(|V_n| > \delta) \quad (3.55)$$

が成り立つ. (3.55) の $n \rightarrow \infty$ での極限を取ると, $U_n \xrightarrow{d} U, V_n \xrightarrow{p} 0$ であるから,

$$\begin{aligned} 0 \leq \lim_{n \rightarrow \infty} \mathbb{P}(|U_n V_n| > \epsilon) &\leq \lim_{n \rightarrow \infty} \mathbb{P}(|U_n| > \epsilon/\delta) + \lim_{n \rightarrow \infty} \mathbb{P}(|V_n| > \delta) \\ &= \mathbb{P}(|U| > \epsilon/\delta) + 0 \end{aligned} \quad (3.56)$$

となる^[5]. $\delta \rightarrow \infty$ とすると, (3.56) の右辺は 0 に収束するので, $U_n V_n \xrightarrow{p} 0$ が示される. ■

3.4 順序統計量

r.v. $X_1, \dots, X_n$ を確率分布 P から無作為標本とする. 例によって, この標本から母集団の平均 μ や分散 σ^2 を推定する問題を考える. このとき, $X_1, \dots, X_n$ の値のみが推定に必要であり, その順番は不必要な情報だと考えられる. そこで, n 個の標本を昇順に並べ替えた $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ を統計量と考え, これを元に推定をするのが自然である.

定義 3.3: 順序統計量 (order statistics)

$X_1, \dots, X_n$ を確率分布 P から無作為標本, すなわち $X_1, \dots, X_n$ i.i.d. $\sim P$ とする. 小さい順に並べ替えたものを $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ で表し順序統計量 (order statistics) という.

$x_1 < x_2 < \dots < x_n$ とし, $x_1, x_2, \dots, x_n$ 上に確率を持つ離散型 r.v. を考える. ここで或る 1 つの標本 X_1 について,

$$\mathbb{P}(X_1 = x_i) = p_i, \quad P_i = \mathbb{P}(X_1 \leq x_i) \quad (3.57)$$

とおく. このとき, $P_0 = 0, P_1 = p_1, \dots, P_i = p_1 + p_2 + \dots + p_i, \quad (i = 1, \dots, n)$ となる.

[5] $h(U_n) = |U_n|$ と定義すれば $h(U_n) \xrightarrow{d} h(U)$ が成り立つので, $|U_n| \xrightarrow{d} |U|$ となり, $\lim_{n \rightarrow \infty} \mathbb{P}(|U_n| > \epsilon/\delta) = \mathbb{P}(|U| > \epsilon/\delta)$ と書ける.

命題 3.10:

$X_{(j)}$ の分布関数は次で与えられる.

$$\mathbb{P}(X_{(j)} \leq x_i) = \sum_{k=j}^n \binom{n}{k} P_i^k (1 - P_i)^{n-k} \quad (3.58)$$

Proof 標本 $X_1, \dots, X_n$ の中の或るサンプル X_k に注目する. $x_i \in \mathbb{R}$ を固定し,

$X_k \leq x_i$ なら”成功”

$X_k > x_i$ なら”失敗”

という事象を考える. このとき (3.57) から, X_k が”成功”, ”失敗”する確率はそれぞれ,

$$\begin{aligned} \mathbb{P}(X_k \leq x_i) &= P_i \\ \mathbb{P}(X_k > x_i) &= 1 - P_i \end{aligned} \quad (3.59)$$

となり, この事象は標本空間を $\Omega = \{X_k \leq x_i, X_k > x_i\}$ と定めたベルヌーイ試行である. 更に, $(\Omega, \mathbb{P})$ 上の r.v. $Z_k : \Omega \rightarrow \mathbb{R}$ を

$$Z_k = \begin{cases} 1 & (X_k \leq x_i) \\ 0 & (X_k > x_i) \end{cases} \quad (3.60)$$

により定める. $X_1, \dots, X_n$ i.i.d. $\sim P$ より, $Z_1, \dots, Z_n$ も互いに独立である.

新しい r.v. $Y = \sum_{k=1}^n Z_k$ を考えると, Y は n 回のベルヌーイ試行の成功回数を表すので, $Y \sim \text{Bin}(n, P_i)$ となる. すなわち,

$$\mathbb{P}(Y = k) = \binom{n}{k} P_i^k (1 - P_i)^{n-k}, \quad k = 0, 1, \dots, n \quad (3.61)$$

である.

さて, $X_{(j)} \leq x_i$ は, 標本 $X_1, \dots, X_n$ の少なくとも j 個が x_i 以下であるという意味である. これは r.v. Y が少なくとも j 回成功する, つまり $Y \geq j$ であることと同値である. したがって,

$$\begin{aligned} \mathbb{P}(X_{(j)} \leq x_i) &= \mathbb{P}(Y \geq j) = \sum_{k=j}^n \mathbb{P}(Y = k) \\ &= \sum_{k=j}^n \binom{n}{k} P_i^k (1 - P_i)^{n-k} \end{aligned} \quad (3.62)$$

となる. ■

証明の補足: 事象 $\{X_{(j)} \leq x_i\}$ と事象 $\{Y \geq j\}$ の同値性, $\{X_{(j)} \leq x_i\} \Leftrightarrow \{Y \geq j\}$

$X_{(j)} \leq x_i$ は「標本 $X_1, \dots, X_n$ の中の j 番目に小さい値が x_i 以下である」ということである. このとき,

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(j)} \leq x_i$$

が成り立つ. したがって, 標本 $X_1, \dots, X_n$ の中に x_i 以下の値が少なくとも j 個存在することになる. Y は x_i 以下となった標本の個数を表す r.v. であるから, $Y \geq j$ となる.

逆に, $Y \geq j$ は, 「標本 $X_1, \dots, X_n$ の中に x_i 以下の値が少なくとも j 個存在する」ことである. このとき仮に, $X_{(j)} > x_i$ であったとすると,

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(j-1)} \leq x_i < X_{(j)}$$

となり, 標本 $X_1, \dots, X_n$ の中に x_i 以下の値は高々 $j-1$ 個しか存在しない, つまり $Y \leq j-1$ ということになる. これは $Y \geq j$ と矛盾する. したがって, $Y \geq j$ ならば, $X_{(j)} \leq x_i$ である.